KLASIFIKASI DALAM SUPERVISED LEARNING

1. Pendahuluan

Di era digital, setiap hari internet menghasilkan data dalam jumlah sangat besar: komentar media sosial, caption, review produk, judul berita, hashtag, hingga respons publik terhadap konten viral. Indonesia sendiri memiliki tingkat penggunaan digital dan media sosial yang sangat tinggi, sehingga data internet menjadi sumber yang sangat kaya untuk dianalisis.

Salah satu cara memahami data tersebut adalah melalui **klasifikasi**. Klasifikasi digunakan untuk menjawab pertanyaan seperti:

- apakah komentar ini positif atau negatif,
- apakah judul ini clickbait atau informatif,
- apakah review ini menunjukkan produk layak dibeli atau tidak,
- apakah konten ini edukatif atau hanya sensasional.

Dalam machine learning, klasifikasi termasuk ke dalam **supervised learning**, yaitu metode pembelajaran mesin yang menggunakan data yang sudah memiliki label. Modul sumber juga menjelaskan bahwa supervised learning melatih model menggunakan data berlabel, lalu memakainya untuk memprediksi data baru.

Jadi, inti supervised learning adalah:

- ada data contoh,
- ada label jawaban,
- model belajar dari pola,
- lalu model memprediksi data baru.

---

2. Apa Itu Supervised Learning?

Supervised learning adalah metode machine learning yang bekerja dengan data yang sudah diketahui hasil atau labelnya.

Contoh:

- email → spam / bukan spam
- komentar → positif / negatif
- review → layak beli / tidak layak beli
- berita → clickbait / informatif

Model mempelajari hubungan antara:

- **input** = fitur atau atribut data

- **output** = label atau kelas

Setelah itu, model digunakan untuk memprediksi label pada data yang belum pernah dilihat sebelumnya.

Ciri utama supervised learning

1. memiliki data input,
2. memiliki label output,
3. model belajar dari pasangan input-output,
4. tujuan akhirnya adalah prediksi.

---

3. Klasifikasi dan Regresi

Modul sumber membedakan dua tugas utama dalam supervised learning, yaitu **classification** dan **regression**.

3.1 Klasifikasi

Klasifikasi adalah proses memprediksi **kategori**.

Contoh:

- komentar → positif / negatif / netral
- email → spam / bukan spam
- review → layak beli / tidak layak beli
- judul konten → clickbait / informatif

Hasil akhirnya berupa **label**.

3.2 Regresi

Regresi adalah proses memprediksi **nilai angka**.

Contoh:

- harga rumah
- jumlah penjualan
- suhu udara
- jumlah penonton konten

Hasil akhirnya berupa **angka**, bukan kategori.

3.3 Perbedaan singkat

Aspek	Klasifikasi	Regresi

Hasil	Kategori	Nilai numerik
Contoh	Positif / negatif	Harga rumah
Tujuan	Menentukan kelas	Menentukan nilai

Cara paling mudah mengingat

Kalau jawabannya berupa **nama kelompok**, itu klasifikasi.
Kalau jawabannya berupa **angka**, itu regresi.

---

4. Mengapa Klasifikasi Penting?

Klasifikasi penting karena banyak keputusan modern sebenarnya berbentuk kategorisasi.

Contoh di dunia digital:

- ribuan komentar publik ingin diketahui sentimennya,
- review produk ingin dipilah menjadi dukungan atau keluhan,
- judul berita ingin diuji apakah informatif atau clickbait,
- konten viral ingin dikelompokkan menjadi edukatif, hiburan, promosi, atau sensasional.

TikTok sendiri menekankan bahwa platformnya menjadi tempat orang menemukan produk, restoran, tren kecantikan, destinasi, dan bisnis kecil, sehingga konten yang muncul di media sosial sering langsung memengaruhi pencarian, kunjungan, dan keputusan pembelian. TikTok juga menyoroti bahwa tren 2026 bergerak lewat momen budaya, kreativitas, dan komunitas niche.

Artinya, klasifikasi bukan hanya soal teori komputer, tetapi juga alat untuk membaca perilaku publik digital.

---

5. Komponen Dasar Masalah Klasifikasi

Setiap kasus klasifikasi biasanya terdiri dari tiga komponen utama.

5.1 Objek

Objek adalah data yang akan diprediksi.

Contoh:

- satu komentar,
- satu review produk,
- satu judul berita,
- satu caption video.

5.2 Fitur

Fitur adalah ciri-ciri yang digunakan model untuk membuat prediksi.

Contoh fitur komentar:

- kata “bagus”
- kata “kecewa”
- jumlah emoji
- panjang teks
- ada/tidaknya kata “viral”

5.3 Label

Label adalah hasil kategori yang ingin diprediksi.

Contoh:

- positif / negatif / netral
- clickbait / informatif
- layak beli / tidak layak beli

---

6. Alur Kerja Klasifikasi

Modul sumber sudah menunjukkan alur umum machine learning: data dikumpulkan, dibersihkan, diproses, model dilatih, diuji, lalu dievaluasi.

Berikut versi yang lebih jelas.

Langkah 1: Kumpulkan data

Data bisa berasal dari:

- komentar publik media sosial,
- review marketplace,
- caption konten,
- judul berita,
- hasil crawling web.

Langkah 2: Bersihkan data

Data mentah biasanya belum siap pakai.

Contoh masalah:

- ada simbol berlebihan,

- ada URL,
- ada emoji berulang,
- ada teks duplikat,
- ada campuran huruf besar-kecil.

Langkah 3: Tentukan fitur

Pilih unsur data yang dianggap penting.

Langkah 4: Beri label

Sebagian data perlu diberi label manual untuk dijadikan data latih.

Langkah 5: Bagi data

Data dibagi menjadi:

- training data
- testing data

Langkah 6: Latih model

Model mempelajari pola hubungan fitur dengan label.

Langkah 7: Prediksi data baru

Model mengklasifikasikan data yang belum pernah dilihat.

Langkah 8: Evaluasi

Hasil prediksi dibandingkan dengan label sebenarnya.

---

7. Data Preprocessing

Sebelum model dilatih, data perlu dipersiapkan. Modul sumber menekankan bahwa preprocessing bertujuan meningkatkan kualitas data agar model belajar lebih baik.

Dalam kasus data internet, preprocessing justru sangat penting karena data teks dari media sosial cenderung berantakan.

7.1 Pembersihan teks

Contoh langkah:

- ubah semua huruf menjadi lowercase,
- hapus tanda baca yang tidak perlu,

- hapus URL,
- hapus mention,
- hapus komentar ganda,
- rapikan spasi.

Contoh:
“BAGUSSS!!! ini viral bgt 😭 🔥 ”
menjadi
“bagus ini viral banget”

7.2 Menghapus noise

Noise adalah bagian data yang tidak membantu klasifikasi.

Contoh:

- spam karakter,
- simbol berulang,
- link promosi,
- tag tidak relevan.

7.3 Stopword removal

Beberapa kata sangat sering muncul tetapi kurang bermakna untuk klasifikasi.

Contoh:

- yang
- dan
- di
- ke
- dari

7.4 Stemming atau lemmatization

Kata dikembalikan ke bentuk dasarnya.

Contoh:

- membeli → beli
- dibelikan → beli
- bagusnya → bagus

Tujuannya agar model membaca kata-kata sejenis sebagai satu makna.

---

8. Encoding, Scaling, dan Outlier

Modul sumber membahas tiga hal penting ini.

8.1 Encoding

Komputer tidak memahami kategori teks secara langsung, sehingga beberapa data kategori perlu diubah menjadi angka.

Contoh:

- positif = 1
- negatif = 0

8.2 Feature scaling

Scaling membantu ketika ada fitur dengan skala yang berbeda jauh, terutama pada algoritma berbasis jarak seperti k-NN. Modul sumber juga menjelaskan normalization dan standardization untuk tujuan ini.

8.3 Outlier

Outlier adalah data yang sangat berbeda dari mayoritas data lain. Pada data sosial media, outlier bisa berupa:

- komentar sangat panjang,
- spam emoji berlebihan,
- jumlah likes ekstrem,
- akun bot yang mengulang teks sama.

Outlier perlu diperiksa karena bisa memengaruhi hasil model.

---

9. Metode Klasifikasi yang Umum

Modul sumber memperkenalkan beberapa metode klasifikasi umum: Naive Bayes, Nearest Neighbor, dan Linear Classifier.

9.1 Naive Bayes

Menggunakan probabilitas untuk menentukan kelas data.

Cocok untuk:

- klasifikasi teks,
- deteksi spam,
- analisis sentimen sederhana.

Kelebihan:

- cepat,
- mudah dipahami,
- efektif untuk teks.

9.2 k-Nearest Neighbor

Menentukan kelas berdasarkan tetangga terdekat.

Cocok untuk:

- data numerik,
- kasus kemiripan antarobjek.

9.3 Linear Classifier

Menggunakan batas pemisah untuk membedakan kelas.

Contoh:

- komentar positif dan negatif dipisahkan berdasarkan kombinasi fitur tertentu.

---

10. Studi Kasus Utama

Klasifikasi Sentimen Komentar pada Konten Viral Media Sosial

Agar lebih relevan untuk mahasiswa, kita gunakan contoh dari dunia digital yang dekat dengan keseharian mereka: **komentar pada konten viral**.

TikTok dan platform video pendek lain terus menjadi pusat munculnya tren, percakapan publik, dan minat niche. Laporan tren resmi TikTok untuk 2026 menekankan peran komunitas, momen budaya, dan kreativitas yang memicu percakapan luas.

10.1 Permasalahan

Sebuah tim ingin mengetahui bagaimana respons publik terhadap sebuah konten viral.

10.2 Tujuan klasifikasi

Mengelompokkan komentar menjadi:

- positif
- negatif

- netral

10.3 Contoh data mentah hasil crawling

No	Komentar
1	“bagus banget, relate parah”
2	“lebay, isinya biasa aja”
3	“aku baru lihat ini tadi malam”
4	“keren sih, editnya niat”
5	“cringe banget jujur”
6	“lumayan, tapi nggak spesial”

10.4 Label manual

No	Komentar	Label
1	bagus banget, relate parah	Positif
2	lebay, isinya biasa aja	Negatif
3	aku baru lihat ini tadi malam	Netral
4	keren sih, editnya niat	Positif
5	cringe banget jujur	Negatif
6	lumayan, tapi nggak spesial	Netral

10.5 Fitur yang dapat digunakan

- kata positif: bagus, keren, relate, lucu
- kata negatif: lebay, cringe, bohong, jelek
- jumlah kata
- jumlah emoji
- penggunaan huruf kapital
- hashtag tertentu

10.6 Penjelasan mudah

Kalau komentar banyak berisi kata-kata dukungan, model cenderung memberi label **positif**. Kalau komentar berisi kata penolakan atau hinaan, model cenderung memberi label **negatif**. Kalau komentar hanya informatif tanpa penilaian kuat, model bisa memberi label **netral**.

10.7 Kenapa studi kasus ini bagus?

- dekat dengan kehidupan mahasiswa,
- datanya mudah ditemukan,
- menunjukkan bahwa AI bisa membaca opini publik,
- relevan dengan budaya digital saat ini. Indonesia sendiri memiliki ratusan juta koneksi seluler aktif dan penggunaan digital yang sangat besar, sehingga data sosial menjadi medan belajar yang sangat masuk akal untuk konteks pembelajaran.

---

11. Studi Kasus Tambahan

Klasifikasi Judul Konten: Informatif atau Clickbait

Mahasiswa juga sangat akrab dengan judul-judul sensasional di media sosial dan portal berita.

Contoh data

Judul	Label
“5 fakta tentang skincare yang sering disalahpahami”	Informatif
“Nomor 3 bikin kamu shock!”	Clickbait
“Cara cek keamanan link sebelum diklik”	Informatif
“Rahasia ini akhirnya terbongkar!!!”	Clickbait

Fitur yang bisa digunakan

- ada angka dramatis,
- ada kata “shock”, “parah”, “terbongkar”,
- ada tanda seru berlebihan,
- ada frasa penjelas yang konkret atau tidak.

Manfaat

Kasus ini bagus untuk:

- literasi digital,
- analisis media,
- membedakan informasi dengan sensasi.

---

12. Contoh Implementasi Sederhana

12.1 Implementasi konseptual tanpa coding

Mahasiswa non-IT bisa mulai dari logika dulu.

Langkah:

1. ambil 50 komentar dari konten viral,
2. bersihkan teks,
3. beri label manual,
4. catat kata-kata yang sering muncul pada tiap kelas,
5. gunakan pola itu untuk memprediksi komentar baru.

Contoh:

Komentar baru:
“keren banget, editnya niat”

Karena ada kata:

- keren
- banget
- niat

yang sering muncul pada komentar positif, maka model cenderung memberi label **positif**.

12.2 Implementasi dengan spreadsheet

Ini cocok untuk kelas awal.

Langkah:

1. simpan komentar di Excel atau Google Sheets,
2. buat kolom:
    - komentar
    - label
    - ada kata “bagus”?
    - ada kata “cringe”?
    - ada kata “viral”?
3. hitung frekuensi fitur di tiap kelas,
4. gunakan perhitungan probabilitas sederhana,
5. tentukan kelas dengan peluang terbesar.

Manfaat

- tidak perlu coding,
- mahasiswa bisa melihat proses dengan jelas,
- mudah didemonstrasikan dosen.

12.3 Implementasi dengan Python sederhana

Untuk pengantar praktik modern, mahasiswa dapat diperkenalkan alur implementasi berikut:

1. crawling komentar publik,
2. preprocessing teks,
3. ubah teks menjadi fitur,
4. bagi training-testing,
5. latih model,
6. prediksi,
7. evaluasi.

Pseudocode sederhana

```
Ambil data komentar
Bersihkan teks
Beri label sentimen
Ubah teks menjadi fitur kata
Bagi data menjadi training dan testing
Latih model klasifikasi
Prediksi data testing
Hitung akurasi
Analisis hasil
```

Mahasiswa tidak harus langsung fokus ke sintaks. Yang lebih penting:

- apa input-nya,
- apa prosesnya,
- apa output-nya.

---

13. Evaluasi Model

Modul sumber menyebut akurasi sebagai metrik evaluasi paling sederhana.

13.1 Akurasi

Rumus:

$$Accuracy = \frac{Jumlah\ prediksi\ benar}{Jumlah\ seluruh\ data}$$

Contoh

Jika dari 20 komentar, model memprediksi 16 dengan benar:

$$Accuracy = \frac{16}{20} = 0.8 = 80\%$$

Artinya model benar pada 80% data uji.

13.2 Mengapa evaluasi penting?

Karena model tidak boleh langsung dipercaya hanya karena “terlihat pintar”. Evaluasi diperlukan untuk memastikan:

- model tidak asal menebak,
- fitur yang dipilih memang berguna,

- hasil cukup layak dipakai.

---

14. Etika Penggunaan Data Crawling

Karena contoh modul ini memakai data internet, mahasiswa perlu memahami etika dasarnya.

Prinsip penting:

- gunakan data yang bersifat publik,
- jangan mengambil data akun privat,
- jangan menyebarkan identitas personal,
- gunakan data hanya untuk pembelajaran,
- patuhi aturan platform dan etika penelitian.

Ini penting agar mahasiswa tidak hanya cakap teknis, tetapi juga bertanggung jawab secara akademik.

---

15. Poin Penting untuk Mahasiswa Non-IT

1. Machine learning bukan sulap.
   Sistem hanya belajar dari pola data.
2. Klasifikasi adalah bentuk pengelompokan otomatis.
   Mirip seperti manusia membedakan komentar mendukung atau menghina.
3. Data yang baik sangat menentukan hasil.
   Kalau data kacau, model juga akan kacau.
4. Tidak semua implementasi harus mulai dari coding.
   Bisa mulai dari tabel, logika, dan spreadsheet.
5. Contoh kasus digital lebih dekat ke kehidupan nyata.
   Karena hampir semua mahasiswa hidup di ekosistem media sosial.

---

16. Ringkasan Materi

- Supervised learning menggunakan data berlabel.
- Klasifikasi memprediksi kategori, bukan angka.
- Data internet seperti komentar, caption, dan review sangat cocok untuk latihan klasifikasi.
- Sebelum model dilatih, data perlu melalui preprocessing.
- Metode klasifikasi yang umum antara lain Naive Bayes, k-NN, dan Linear Classifier.
- Contoh yang relevan saat ini adalah klasifikasi sentimen komentar konten viral dan klasifikasi judul clickbait.
- Model perlu dievaluasi, salah satunya dengan akurasi.
- Penggunaan data crawling harus tetap memperhatikan etika.

---

17. Latihan Pemahaman

Soal 1

Jelaskan dengan bahasa Anda sendiri apa itu supervised learning.

Soal 2

Apa perbedaan klasifikasi dan regresi? Berikan masing-masing 2 contoh.

Soal 3

Mengapa komentar media sosial cocok dijadikan data klasifikasi?

Soal 4

Jelaskan mengapa preprocessing penting pada data crawling dari internet.

Soal 5

Sebuah model memprediksi 18 dari 24 komentar dengan benar. Berapa akurasinya?

---

18. Tugas Sederhana

Ambil satu tema konten viral dari media sosial atau berita internet, lalu jelaskan:

1. objek yang akan diklasifikasikan,
2. kelas target yang digunakan,
3. fitur yang mungkin dipakai,
4. langkah preprocessing yang diperlukan,
5. cara mengevaluasi modelnya.

---

19. Penutup

Klasifikasi dalam supervised learning adalah fondasi penting dalam memahami bagaimana sistem cerdas bekerja. Dengan memakai contoh dari komentar viral, review, dan judul konten internet, mahasiswa dapat melihat bahwa machine learning tidak jauh dari kehidupan sehari-hari. Justru, banyak fenomena digital yang mereka lihat setiap hari sebenarnya dapat dianalisis dengan konsep klasifikasi. Penggunaan contoh berbasis budaya internet ini juga sejalan dengan peran besar platform sosial dalam membentuk percakapan publik, penemuan tren, dan keputusan pengguna saat ini