Klasifikasi dalam Supervised Learning

Memahami cara mesin belajar mengelompokkan data — dari komentar viral hingga judul clickbait.

PENDAHULUAN

Data Digital Ada di Mana-Mana

Indonesia memiliki tingkat penggunaan digital dan media sosial yang sangat tinggi. Setiap hari, internet menghasilkan data masif: komentar, review, caption, judul berita, dan hashtag.

Klasifikasi menjawab pertanyaan seperti:

- Apakah komentar ini **positif atau negatif**?
- Apakah judul ini **clickbait atau informatif**?
- Apakah konten ini **edukatif atau sensasional**?

KONSEP DASAR

Apa Itu Supervised Learning?

Supervised learning adalah metode machine learning yang bekerja dengan data yang sudah diketahui labelnya.

Input

Fitur atau atribut data (misalnya kata dalam komentar)

Label

Jawaban yang sudah diketahui (positif / negatif / spam)

Model Belajar

Menemukan pola dari pasangan input-output

Prediksi

Mengklasifikasikan data baru yang belum pernah dilihat

KONSEP DASAR

Klasifikasi vs. Regresi

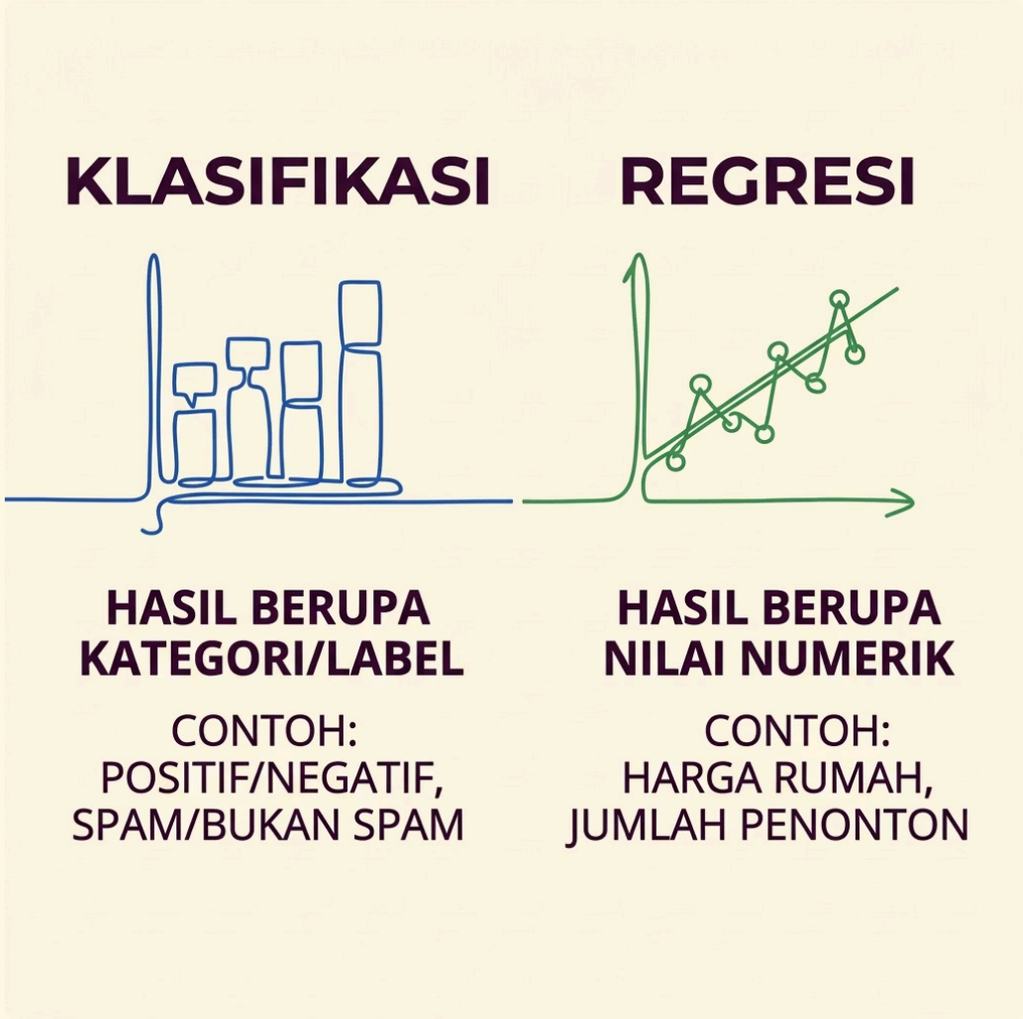

💡 **Cara mudah mengingat:** Kalau jawabannya berupa **nama kelompok** → klasifikasi. Kalau jawabannya berupa **angka** → regresi.

Modul ini berfokus pada **klasifikasi** — memprediksi kategori dari data digital seperti komentar dan judul konten.

Mengapa Klasifikasi Penting?

Banyak keputusan modern berbentuk kategorisasi. TikTok menekankan platformnya sebagai tempat orang menemukan produk, tren, dan bisnis kecil — konten yang muncul langsung memengaruhi keputusan pengguna. Tren 2026 bergerak lewat **momen budaya, kreativitas, dan komunitas niche**.

Klasifikasi adalah alat untuk **membaca perilaku publik digital**, bukan sekadar teori komputer.

KOMPONEN

Tiga Komponen Dasar Klasifikasi

Objek

Data yang akan diprediksi: satu komentar, satu review produk, satu judul berita, satu caption video.

Fitur

Ciri-ciri untuk prediksi: kata "bagus", kata "kecewa", jumlah emoji, panjang teks, ada/tidaknya kata "viral".

Label

Hasil kategori yang diprediksi: positif/negatif/netral, clickbait/informatif, layak beli/tidak.

ALUR KERJA

Alur Kerja Klasifikasi

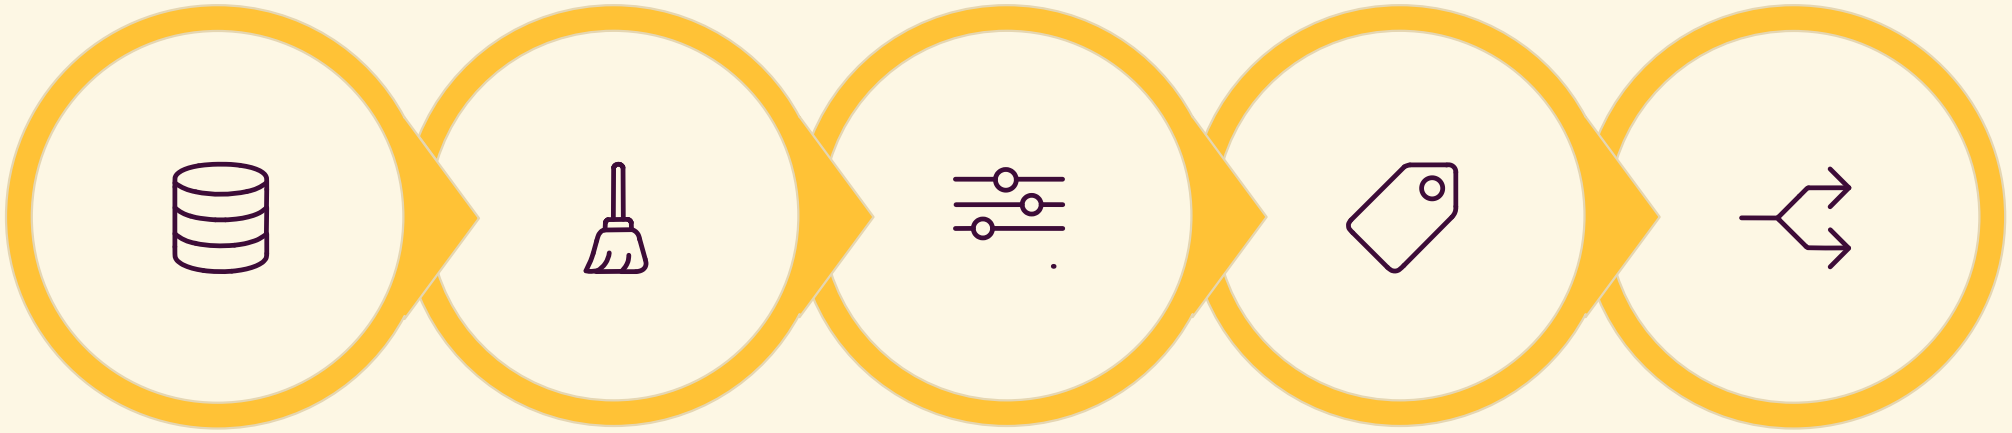

Kumpulkan Data → **Bersihkan Data** → **Tentukan Fitur** → **Beri Label** → **Bagi Data**

Data bisa berasal dari komentar media sosial, review marketplace, caption konten, atau hasil crawling web. Setiap langkah memastikan model belajar dari data berkualitas.

PREPROCESSING

Data Preprocessing: Membersihkan Data Mentah

Data teks dari media sosial cenderung berantakan. Preprocessing meningkatkan kualitas data agar model belajar lebih baik.

> "BAGUSSS!!! ini viral bgt 😱🔥"
> → **"bagus ini viral banget"**

Pembersihan Teks

Lowercase, hapus tanda baca, URL, mention, spasi berlebih

Hapus Noise

Spam karakter, simbol berulang, link promosi, tag tidak relevan

Stopword Removal

Hapus kata umum: yang, dan, di, ke, dari

Stemming

membeli → beli, bagusnya → bagus

PREPROCESSING

Encoding, Scaling, dan Outlier

Encoding

Ubah kategori teks ke angka.
Contoh: positif = 1, negatif = 0

Feature Scaling

Normalisasi fitur berskala berbeda, terutama untuk algoritma berbasis jarak seperti k-NN

Outlier

Data ekstrem seperti komentar sangat panjang, spam emoji, atau akun bot perlu diperiksa karena memengaruhi model

METODE

Metode Klasifikasi yang Umum

1

Naive Bayes

Menggunakan probabilitas. Cocok untuk klasifikasi teks, deteksi spam, analisis sentimen. Cepat dan efektif.

2

k-Nearest Neighbor

Menentukan kelas berdasarkan tetangga terdekat. Cocok untuk data numerik dan kasus kemiripan antarobjek.

3

Linear Classifier

Menggunakan batas pemisah untuk membedakan kelas berdasarkan kombinasi fitur tertentu.

STUDI KASUS UTAMA

Klasifikasi Sentimen Komentar Konten Viral

TikTok dan platform video pendek menjadi pusat tren dan percakapan publik. Laporan tren TikTok 2026 menekankan peran **komunitas, momen budaya, dan kreativitas**. Sebuah tim ingin mengetahui respons publik terhadap konten viral dengan mengelompokkan komentar menjadi **positif, negatif, atau netral**.

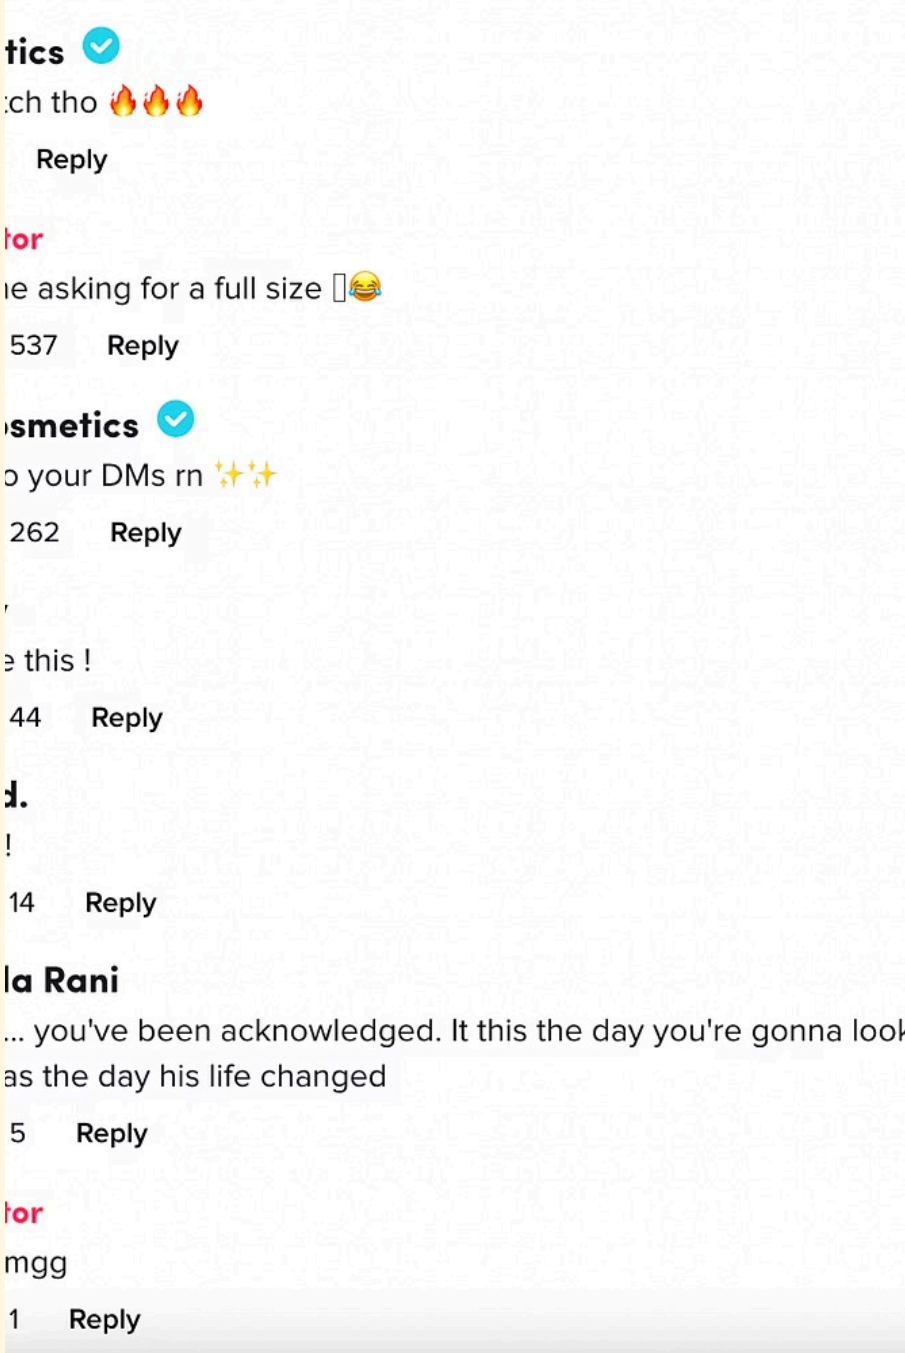

STUDI KASUS UTAMA

Data Mentah & Label Manual

No	Komentar	Label
1	bagus banget, relate parah	Positif
2	lebay, isinya biasa aja	Negatif
3	aku baru lihat ini tadi malam	Netral
4	keren sih, editnya niat	Positif
5	cringe banget jujur	Negatif
6	lumayan, tapi nggak spesial	Netral

STUDI KASUS UTAMA

Fitur & Logika Prediksi

Fitur yang Digunakan

Kata Positif

bagus, keren, relate, lucu

Kata Negatif

lebay, cringe, bohong, jelek

Fitur Lain

jumlah kata, emoji, huruf kapital, hashtag

Logika Prediksi

→ Positif

Banyak kata dukungan

→ Negatif

Kata penolakan atau hinaan

→ Netral

Informatif tanpa penilaian kuat

STUDI KASUS TAMBAHAN

Klasifikasi Judul: Informatif atau Clickbait?

Judul	Label
5 fakta tentang skincare yang sering disalahpahami	Informatif
Nomor 3 bikin kamu shock!	Clickbait
Cara cek keamanan link sebelum diklik	Informatif
Rahasia ini akhirnya terungkap!!!	Clickbait

Fitur Clickbait

- Angka dramatis
- Kata "shock", "parah", "terungkap"
- Tanda seru berlebihan
- Tidak ada frasa penjelas konkret

Kasus ini mendukung **literasi digital** dan kemampuan membedakan informasi dari sensasi.

IMPLEMENTASI

Tiga Cara Implementasi Klasifikasi

1

Konseptual

Tanpa coding. Ambil 50 komentar, beri label manual, catat pola kata per kelas, prediksi komentar baru.

2

Spreadsheet

Excel/Google Sheets. Buat kolom fitur, hitung frekuensi, gunakan probabilitas sederhana. Cocok untuk kelas awal.

3

Python

Crawling → preprocessing → ekstraksi fitur → training → prediksi → evaluasi. Fokus pada alur, bukan sintaks.

IMPLEMENTASI

Pseudocode Sederhana

Ambil data komentar
Bersihkan teks
Beri label sentimen
Ubah teks menjadi fitur kata
Bagi data → training & testing
Latih model klasifikasi
Prediksi data testing
Hitung akurasi
Analisis hasil

Mahasiswa tidak harus langsung fokus ke sintaks. Yang lebih penting: **apa input-nya, apa prosesnya, apa output-nya.**

Contoh prediksi: komentar *"keren banget, editnya niat"* mengandung kata positif → model memberi label **Positif**.

EVALUASI

Evaluasi Model: Akurasi

Rumus Akurasi

$$Accuracy = \frac{\text{Jumlah prediksi benar}}{\text{Jumlah seluruh data}}$$

Contoh: dari 20 komentar, model benar pada 16:

$$Accuracy = \frac{16}{20} = 0.8 = 80\%$$

Mengapa Evaluasi Penting?

→ Memastikan model tidak asal menebak

→ Membuktikan fitur yang dipilih berguna

→ Menentukan apakah hasil layak dipakai

ETIKA

Etika Penggunaan Data Crawling

✅ Gunakan data publik

Jangan ambil data akun privat

🔒 Lindungi identitas

Jangan sebarkan data personal

📚 Tujuan pembelajaran

Patuhi aturan platform dan etika penelitian

POIN PENTING

5 Poin untuk Mahasiswa Non-IT

1. **Machine learning bukan sulap**

   Sistem hanya belajar dari pola data.

2. **Data yang baik menentukan hasil**

   Kalau data kacau, model juga akan kacau.

3. **Tidak harus mulai dari coding**

   Bisa mulai dari tabel, logika, dan spreadsheet.

4. **Contoh digital dekat ke kehidupan nyata**

   Hampir semua mahasiswa hidup di ekosistem media sosial.

5. **Klasifikasi = pengelompokan otomatis**

   Mirip seperti manusia membedakan komentar mendukung atau menghina.

RINGKASAN

Ringkasan Materi

01

Supervised Learning

Menggunakan data berlabel untuk melatih model prediksi.

02

Klasifikasi vs Regresi

Klasifikasi → kategori; Regresi → angka.

03

Preprocessing

Data internet perlu dibersihkan sebelum dilatih.

04

Metode Umum

Naive Bayes, k-NN, Linear Classifier.

05

Evaluasi & Etika

Ukur akurasi model; gunakan data crawling secara bertanggung jawab.

LATIHAN

Latihan Pemahaman

1

Jelaskan dengan bahasa Anda sendiri apa itu **supervised learning**.

2

Apa perbedaan **klasifikasi dan regresi**? Berikan masing-masing 2 contoh.

3

Mengapa **komentar media sosial** cocok dijadikan data klasifikasi?

4

Mengapa **preprocessing** penting pada data crawling dari internet?

5

Model memprediksi **18 dari 24 komentar** dengan benar. Berapa akurasinya?

TUGAS

Tugas Sederhana

Ambil satu tema konten viral dari media sosial atau berita internet, lalu jelaskan:

1. **Objek**
   Apa yang akan diklasifikasikan?

2. **Kelas Target**
   Kategori apa yang digunakan?

3. **Fitur**
   Fitur apa yang mungkin dipakai?

4. **Preprocessing**
   Langkah apa yang diperlukan?

5. **Evaluasi**
   Bagaimana cara mengevaluasi modelnya?

Penutup

Klasifikasi dalam supervised learning adalah **fondasi penting** dalam memahami cara sistem cerdas bekerja. Dengan contoh dari komentar viral, review, dan judul konten, mahasiswa dapat melihat bahwa **machine learning tidak jauh dari kehidupan sehari-hari**.

Banyak fenomena digital yang kita lihat setiap hari dapat dianalisis dengan konsep klasifikasi — sejalan dengan peran besar platform sosial dalam membentuk percakapan publik dan keputusan pengguna saat ini.